

Generador Académico RAG

Speech seccionado por integrante para la exposición. Cada parte sirve también como material de estudio: lo que decís y lo que te pueden preguntar.

Grupo 14 · Ciencia de Datos · UTN FRLP

Martin, Tomás · Gentil, Mora · Natalichio, Santiago · Cuenca, Juan Bautista · Ocampo, Simón · Aubert, Lautaro

6 turnos · 10 diapositivas · Duración objetivo: 18 a 24 minutos

SLIDE 1 · APERTURA

Buenas a todos. Somos el Grupo 14 y nuestro proyecto se llama **Generador Académico RAG**. Arranco con una pregunta: [pausa] ¿qué pasa si le pedimos a una IA "armame el plan del próximo cuatrimestre"? Si solo sabe lo genérico de internet, no puede: no conoce **tus** notas, **tus** correlativas, **tu** avance. Eso es justo lo que resolvimos.

SLIDE 2 · EL PROBLEMA

Y acá la primera aclaración importante, porque es la crítica que nos íbamos a comer: "che, eso lo hace un SQL". Y es verdad... **si** el producto fueran consultas tipo "¿qué nota tengo en Bases de Datos?". Eso es **lookup**, buscar un dato, no es IA generativa.

Nuestro reencuadre fue ese: el producto no son respuestas, son **artefactos nuevos generados** (un plan justificado, un informe, una carta de pasantía). El SQL te dice qué **podés** cursar; nuestro sistema te dice qué **conviene** y por qué, redactado. Y tampoco es NotebookLM: la gracia del TP es que el pipeline RAG lo **construimos nosotros** y lo mostramos. Mis compañeros lo van desarmando.

CLAVES PARA ESTUDIAR / SI TE PREGUNTAN

- **Qué hace:** genera artefactos académicos (planes, informes, cartas) anclados en el historial real del grupo y el plan de estudios.
- **"Lo hace un SQL":** no, un SQL hace lookup; nosotros generamos texto nuevo con razonamiento y tono.
- **"Es NotebookLM":** no, construimos el pipeline RAG (chunking, embeddings, vector DB, retrieval) en vez de usar una caja negra.

Cierre: "Para generar bien, primero hay que tener buenos datos. Mora les cuenta con qué trabajamos." → pasa a **Mora**.

SLIDE 3 · DATOS Y EXPLORACIÓN

Gracias, Tomás. El corazón del proyecto son los datos, y son **privados**: el modelo no los conoce. Armamos un corpus de **178 documentos** a partir de PDFs reales: estados académicos y exports de notas de dos integrantes, más el Plan de Sistemas 2023 con todas las correlatividades.

Lo interesante es que el corpus es **mixto**: combinamos lo **estructurado** (cada materia con su nota y su año) con lo **no estructurado** (el texto del plan). El desafío técnico más grande fue el **join**: los códigos de materia no coinciden entre el estado y el plan, así que unimos por el **nombre normalizado**, sin tildes ni mayúsculas. Parseamos las 36 obligatorias con sus correlativas.

Un punto de honestidad: tenemos estados reales de dos de nosotros. Para el diagnóstico grupal de los seis, generamos **cuatro perfiles sintéticos**, siempre **marcados como simulados**. Nunca los presentamos como reales.

CLAVES PARA ESTUDIAR / SI TE PREGUNTAN

- **Corpus**: 178 docs (122 de estados, 36 correlativas, 20 chunks del plan).
- **Por qué normalizar**: los códigos institucionales no coinciden entre documentos; el nombre normalizado es la clave de join.
- **Datos sintéticos**: 4 perfiles por arquetipo, reproducibles (semilla fija) y declarados como simulados.

Cierre: "Con esos datos limpios, Santi les muestra cómo los convertimos en algo que el modelo puede consultar." → pasa a **Santiago**.

3 Natalichio, Santiago

Pipeline RAG · embeddings

Slides 4-5

≈ 4 min

SLIDE 4 · EL PIPELINE RAG

Gracias, Mora. Acá está el núcleo del trabajo. RAG significa **Retrieval-Augmented Generation**: en vez de pedirle al modelo que sepa todo, le **recuperamos** el contexto justo y se lo damos para que genere sobre eso.

El flujo: los PDFs pasan por **pdfplumber** a texto, los convertimos en documentos, los vectorizamos con **MiniLM** (embeddings) y los guardamos en **Chroma**, la base vectorial. Cuando llega un pedido, recuperamos los documentos más relevantes y se los pasamos a **qwen2.5** corriendo local con Ollama. Todo offline y privado.

Un detalle que nos importó: tenemos **dos modos de recuperación**. El **semántico**, por similitud de embeddings, para lenguaje natural; y el **determinístico**, por metadata, para anclar exactamente las materias aprobadas de un alumno. Ese segundo modo es el que garantiza que no se inventen notas.

SLIDE 5 · EL ESPACIO SEMÁNTICO

¿Y cómo sabemos que los embeddings funcionan? Proyectamos las 36 materias con **t-SNE** y se ve que las de la misma área caen juntas. Eso valida que el espacio capturó la estructura del plan, y es lo que habilita el recomendador por **matching semántico**: cruzar dónde te fue bien con materias afines. Eso un SQL no lo puede hacer; necesita similitud sobre texto.

CLAVES PARA ESTUDIAR / SI TE PREGUNTAN

- **RAG**: recuperar contexto relevante y dárselo al modelo para que genere anclado, en vez de confiar en su memoria.
- **Embeddings**: all-MiniLM-L6-v2, local; Chroma como vector DB persistente.
- **Retrieval semántico vs. determinístico**: uno por similitud (lenguaje natural), otro por metadata (grounding exacto).
- **t-SNE**: valida que materias de la misma área quedan cercanas en el espacio.

Cierre: "Ya tenemos el contexto. Juan les muestra qué hacemos con él: generar." → pasa a **Juan Bautista**.

4 Cuenca, Juan Bautista

Generación · prompting · tonos

Slide 6

≈ 3 min

SLIDE 6 · UN DATO, TRES TONOS

Gracias, Santi. Tenemos seis generadores: plan de cursada, informe de trayectoria, carta de pasantía, recomendación de orientación, diagnóstico grupal y simulación what-if. Todos comparten la misma regla de prompting: el modelo usa **exclusivamente** el contexto recuperado y tiene prohibido inventar notas o materias.

Pero lo que lo hace **generativo** de verdad es el **control de tono**. Miren la slide: el mismo dato, "podés cursar Ciencia de Datos", dicho en tres registros. En **técnico** es seco y preciso. En **motivacional** te destaca el logro. En **honesto** te marca también la debilidad sin vueltas.

Los datos son idénticos, salen del mismo contexto. Lo único que cambia es cómo se redacta. Eso es exactamente lo que un reporte fijo o un SQL no pueden darte: es síntesis de texto, no una consulta.

CLAVES PARA ESTUDIAR / SI TE PREGUNTAN

- **6 artefactos:** plan, informe, carta, orientación, diagnóstico grupal, what-if.
- **Anti-alucinación:** el system prompt obliga a usar solo el contexto y a no inventar.
- **Tono:** técnico / motivacional / honesto sobre los mismos datos; es un control de producto, no estético.

Cierre: "¿Y cómo demostramos que esto realmente usa los datos y no chamuya? Simón lo mide en vivo." → pasa a **Simón**.

5 Ocampo, Simón

Demo con/sin RAG · evaluación

Slides 7-8

≈ 4 min

SLIDE 7 · CON RAG VS. SIN RAG (DEMO EN VIVO)

Gracias, Juan. Esta es nuestra demo estrella, y la voy a correr en vivo en la web app. El mismo pedido, un plan de cursada, con un botón: **con RAG** y **sin RAG**.

Con RAG, miren la consola: a la izquierda aparece el contexto que recuperó de la base vectorial, las materias y notas reales, y a la derecha el modelo genera el plan citando esos datos. Sin RAG, le sacamos el contexto: el modelo no tiene de dónde agarrarse, así que se generaliza o directamente inventa materias que no existen.

SLIDE 8 · CÓMO LO MEDIMOS

Y esto no es impresión nuestra, lo **medimos**. La métrica es el **grounding**: qué fracción de los datos de la salida (nombres de materias, notas) aparecen realmente en el contexto. Una salida anclada da grounding cerca de **1.0**; una inventada, cerca de **0.0**. Es un proxy léxico, simple y explicable. Su límite: no es semántico, así que penaliza paráfrasis legítimas, y lo decimos abiertamente.

CLAVES PARA ESTUDIAR / SI TE PREGUNTAN

- **Demo:** mismo input, con/sin contexto; muestra que el valor está en el dato privado.
- **Grounding:** fracción de tokens informativos de la salida presentes en el contexto (0 a 1).
- **Resultado:** anclada ≈ 1.0, inventada ≈ 0.0.
- **Limitación:** léxico, no semántico; no detecta contradicciones sutiles.
- **Si falla la demo en vivo:** mostrar la celda equivalente del notebook.

Cierre: "Más allá de un alumno, esto sirve para todo el grupo. Lautaro cierra con eso."
→ pasa a **Lautaro**.

SLIDE 9 · DIAGNÓSTICO GRUPAL

Gracias, Simón. Para cerrar el lado de análisis: aplicamos **KMeans** sobre el perfil por área de cada integrante y lo proyectamos con PCA. Eso agrupa a la gente por fortalezas afines, y el generador de diagnóstico grupal usa esos clusters para **repartir roles** de un proyecto, con justificación. Es el pipeline de Ciencia de Datos completo: EDA, visualización, clustering, todo conectado al RAG.

SLIDE 10 · CONCLUSIONES

¿Qué demostramos? Cuatro cosas. Una: construimos un pipeline RAG completo, no una caja negra. Dos: el sistema **genera** artefactos con tono, no responde preguntas. Tres: la demo con/sin RAG hace **medible** el valor del conocimiento privado. Y cuatro: hicimos el pipeline de DS entero, de los datos crudos a la evaluación.

Todo esto está en el notebook, el informe, y la web app que vieron funcionando. Muchas gracias. Quedamos para las preguntas.

CLAVES PARA ESTUDIAR / SI TE PREGUNTAN

- **Clustering:** KMeans sobre perfil por área (estandarizado), PCA para visualizar.
- **Cierre del valor:** pipeline propio + generación + evaluación medible + DS completo.
- **"¿Para qué sirve fuera del TP?":** cualquier estudiante podría generar su plan/carta/informe sobre su propio historial.

Fin de la exposición. Reparto de preguntas: técnicas de pipeline → Santiago; datos → Mora; evaluación → Simón.