

Generador Académico RAG

Un sistema de IA generativa que sintetiza artefactos académicos personalizados anclados en el historial real del grupo y el plan de estudios, mediante un pipeline RAG construido de punta a punta.

Grupo 14 · Martin, Gentil, Natalichio, Cuenca, Ocampo, Aubert

Pipeline · pdfplumber → MiniLM → Chroma → qwen2.5 (Ollama)

Entorno · local, offline, privado

01 Planificación y metodología

El objetivo es construir un sistema de IA generativa que, alimentado por una base vectorial con el historial académico del grupo más la documentación de la carrera, **genere artefactos académicos personalizados**: planes de cursada justificados, informes de trayectoria, cartas de pasantía, recomendaciones de orientación, diagnóstico grupal y simulaciones what-if.

El reencuadre central del proyecto fue pasar de un *asistente de preguntas* (que un SQL o NotebookLM resolverían) a un **generador**: cada salida es texto nuevo sintetizado, con razonamiento y estilo, no un campo de una tabla. Un SQL responde qué materias *podés* cursar; este sistema redacta qué *conviene* y por qué, cruzando notas, correlativas y patrón de rendimiento.

La metodología siguió el pipeline de Ciencia de Datos completo: ingesta y preprocesamiento de un corpus mixto, vectorización, análisis exploratorio, visualización, clustering, generación con control de tono y evaluación cuantitativa del anclaje (grounding).

418

documentos en el corpus

36

correlatividades parseadas

6

generadores de artefactos

3

tonos controlables

02 Datos, EDA y preprocesamiento

El corpus combina lo **estructurado** (notas, años y correlatividades) con lo **no estructurado** (chunks del plan de estudios). Las fuentes son PDFs reales: los estados académicos y exports de exámenes de los **seis integrantes del grupo**, y el Plan de Sistemas 2023 (correlatividades del Anexo I y equivalencias del Anexo II).

El preprocesamiento crítico fue el **join entre el estado académico y el plan**: los códigos institucionales no coinciden entre documentos, así que la clave de unión es el *nombre de materia normalizado* (minúsculas, sin tildes ni puntuación). Se parsearon las 36 obligatorias con sus correlativas, resolviendo casos borde como las integradoras, cuyo nombre se parte en dos líneas. El corpus final tiene 418 documentos: 362 de estados académicos, 36 de correlatividades y 20 chunks del plan.

El historial de notas de exámenes usa los nombres del **Plan 2008**, mientras que el estado académico ya migró a los del **Plan 2023**. Para que el cruce no pierda notas aprobadas por equivalencia, incorporamos el **Anexo II** del plan (régimen de equivalencias 2008↔2023) como tabla de canonización de nombres: toda materia se lleva a su nombre 2023 antes del join, con tolerancia a la truncación de nombres largos del PDF. Tras esa normalización, las materias que quedan sin nota numérica son las de nivelación de ingreso (año 0, sin nota) y las aún no cursadas, como corresponde.

El análisis exploratorio trabaja sobre **199 registros reales** de notas (una entrada por materia aprobada con calificación numérica), correspondientes a los seis integrantes. Los promedios van de **7.9 a 8.7**, un grupo parejo y de buen rendimiento; las diferencias aparecen al desagregar por área temática, que es lo que explota el diagnóstico grupal.




Fig. 1 – Distribución de notas por integrante (datos reales de los seis): promedios entre 7.9 y 8.7.




Fig. 2 – Avance académico real por año: materias aprobadas por integrante.




Fig. 3 – Perfil por área temática. Las 36 obligatorias se agrupan en 6 áreas para comparar fortalezas.

03 Pipeline RAG e implementación

El pipeline se construyó en módulos independientes, cada uno con self-checks:

```
extract.py      PDF → texto (pdfplumber)
documents.py    texto → documentos + correlatividades; normalizar() = clave de join
ingest.py       corpus → Chroma; buscar() semántico + obtener() por metadata
rag.py          chat() al LLM local (qwen2.5 vía Ollama); fallback si está apagado
analisis.py     DataFrame de notas reales (6 integrantes) + agregaciones por área
figuras.py      EDA, radar, clustering (KMeans/PCA), t-SNE de embeddings
generar.py      6 generadores de artefactos con control de tono
evaluar.py      grounding léxico + semántico + comparar_con_sin_rag()
```

La vectorización usa **all-MiniLM-L6-v2** (el embedding por defecto de Chroma, local y offline). El retrieval tiene dos modos: **semántico** (similitud de embeddings, para lenguaje natural) y **determinístico** (por metadata, para anclar exactamente las materias aprobadas de un alumno y las correlatividades). La generación corre sobre **qwen2.5 vía Ollama**; si Ollama está apagado, la parte RAG sigue funcionando y devuelve el contexto recuperado.

Estrategia de prompting

El sistema instruye al modelo a usar **exclusivamente** el contexto recuperado y a no inventar notas, materias ni correlatividades. El prompt entrega el contexto como datos citables y una tarea concreta por artefacto. El **control de tono** (técnico, motivacional, honesto) reescribe el mismo dato en distinto registro: es lo que hace al sistema generativo y no un reporte fijo.

"Generás artefactos personalizados usando exclusivamente los datos del contexto. No inventes notas ni materias; si un dato no está en el contexto, no lo afirmes."

04 Clustering y espacio semántico

Sobre el perfil por área (estandarizado) se aplicó **KMeans** y se proyectó a 2D con PCA para visualizar grupos de perfiles afines. Por separado, se proyectaron las 36 obligatorias con **t-SNE sobre sus embeddings**: las materias de la misma área caen juntas, lo que valida que el espacio semántico capturó la estructura del plan, condición necesaria para que el recomendador por matching semántico funcione.

Clustering de perfiles académicos

KMeans (k=3) sobre el perfil por área, proyectado con PCA




Fig. 4 – Clustering de perfiles académicos (KMeans sobre perfil por área, proyección PCA).

Materias en el espacio semántico

t-SNE de los embeddings de las 36 obligatorias, coloreadas por área

- Datos e Inteligencia
- Idiomas
- Infraestructura y Redes
- Matemática y Física
- Programación
- Sistemas y Gestión




Fig. 5 – Las 36 obligatorias en el espacio semántico (t-SNE de embeddings), coloreadas por área.

05 Evaluación: grounding con/sin RAG

Medimos el anclaje con **dos métricas complementarias**. El **grounding léxico** es la fracción de tokens informativos de la salida (nombres de materias y notas numéricas) que aparecen literalmente en el contexto: explicable, pero penaliza la paráfrasis. El **grounding semántico** promedia el máximo coseno entre cada oración de la salida y los fragmentos del contexto (mismos embeddings MiniLM): reconoce la reformulación legítima que el léxico castiga. En la validación, una afirmación anclada obtuvo grounding léxico **1.0** (semántico 0.69) y una inventada **0.0** (semántico 0.34): ambas métricas separan lo anclado de lo inventado.

La **demo estrella** compara el mismo pedido **con RAG** (contexto real) contra **sin RAG** (sin contexto). Sin el conocimiento privado, el modelo no puede anclar: se generaliza o inventa, y el grounding cae. Promediando tres artefactos (plan de cursada, recomendación de orientación e informe de trayectoria), el grounding léxico pasa de **0.74 con RAG a 0.32 sin RAG** —menos de la mitad— y el semántico de **0.61 a 0.52**. La brecha léxica es la más elocuente: sin el contexto, la salida casi no menciona materias ni notas reales. Es la evidencia medible de que el aporte del pipeline no es cosmético sino el corazón del producto.



06 Análisis crítico y conclusiones

El sistema cumple el objetivo: construimos el pipeline RAG completo (no una caja negra) y lo usamos para **generar**, no para responder. La demo con/sin RAG y el grounding hacen visible y medible el valor del conocimiento privado.

Limitaciones

El grounding, aun en su versión semántica, no detecta *contradicciones* sutiles: mide cercanía con el contexto, no consistencia lógica con él. El recomendador por matching se apoya en nombres de materias y correlativas, no en las descripciones reales de cada cátedra. Y el modelo local (qwen2.5 3B) prioriza reproducibilidad offline sobre calidad de redacción: es honesto y anclado, pero su prosa es más simple que la de un modelo grande.

Trabajo futuro

Incorporar las descripciones de cátedras y electivas al corpus para que el recomendador compare contenidos y no solo nombres; sumar al grounding una verificación de consistencia (detección de contradicciones, no solo de cercanía); y ofrecer una corrida opcional con un modelo más grande (p. ej. qwen2.5 7B en una máquina con GPU), dejando el 3B como fallback offline reproducible.

El código, el notebook integrador y la web app de demostración en vivo acompañan este informe como entregables ejecutables.