

— CIENCIA DE DATOS · UTN FRLP 2026

Generador Académico **RAG**

IA generativa que sintetiza artefactos académicos
personalizados, anclados en el historial real del grupo y el
plan de estudios.

Grupo 14

TP Integrador · IA Generativa

Martin, Tomás

Gentil, Mora

Natalichio, Santiago

Cuenca, Juan Bautista

Ocampo, Simón

Aubert, Lautaro

— EL PROBLEMA


Generar, no consultar

"¿Qué notas tengo?" lo resuelve un **SQL**. Eso es lookup, no IA.

- ◆ El producto son **artefactos nuevos**: planes, informes, cartas.
- ◆ Texto sintetizado con razonamiento y estilo, no un campo de tabla.
- ◆ No es NotebookLM: **construimos el pipeline** y lo mostramos.

Un corpus mixto y privado

- ◆ **418 documentos:** estados, notas y plan 2023.
- ◆ Estructurado (notas, años) + no estructurado (plan).
- ◆ Join por **nombre normalizado**: los códigos no coinciden.
- ◆ **199 notas reales** de los 6 integrantes (prom. 7.9–8.7).



Avance académico real por año.

El pipeline RAG, de punta a punta

Cada etapa la construimos nosotros, local y offline. La recuperación tiene dos modos: **semántico** y **determinístico por metadata**.

PDFs → pdfplumber → documentos

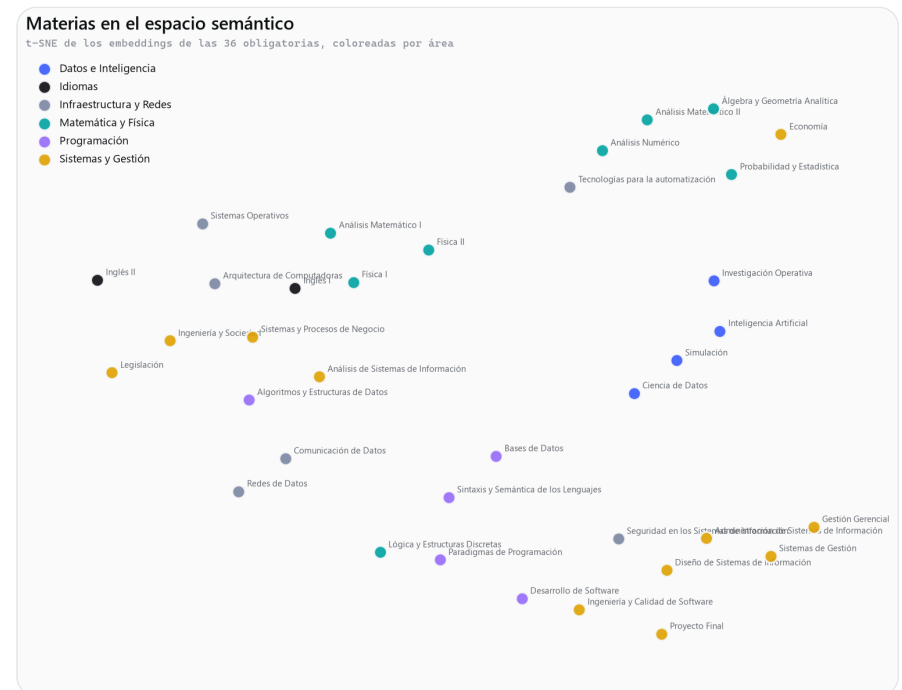
→ embeddings **MiniLM** → **Chroma**

→ retrieval top-k → **contexto**

→ **qwen2.5** (Ollama) → artefacto

El espacio semántico funciona

- ◆ Las 36 obligatorias proyectadas con **t-SNE**.
- ◆ Materias de la misma área caen **juntas**.
- ◆ Eso habilita el **recomendador por matching semántico**: lo que un SQL no puede hacer.



t-SNE de los embeddings de las materias, por área.

— GENERACIÓN

Un dato, tres tonos

TÉCNICO

Podés cursar Ciencia de Datos: cumplís las correlativas. Rendimiento sólido en Programación (media 8.4).

MOTIVACIONAL

¡Vas muy bien! Tu base en Programación es una fortaleza real: Ciencia de Datos es el próximo paso natural.

HONESTO

Estás habilitado, pero arrastrás Matemática floja. Reforzala antes o vas a sufrir la cursada.

Mismos datos del contexto. Solo cambia el [registro](#). Eso es generativo.

— DEMO ESTRELLA

Con RAG vs. sin RAG

CON RAG

Cita las materias aprobadas reales, las correlativas y las notas. Genera el plan anclado.

grounding léxico 0.74

SIN RAG

Sin el historial privado, el modelo se generaliza o inventa materias que no existen.

grounding léxico 0.32

Mismo pedido, un botón. La diferencia es el conocimiento privado.

— EVALUACIÓN

Medimos el anclaje

léxico

tokens de la salida (materias, notas) presentes en el contexto

semántico

coseno de embeddings salida↔contexto;
reconoce paráfrasis


1.0 / 0.0

salida anclada vs. inventada en la validación

Dos métricas complementarias: el léxico es explicable pero castiga la reformulación; el semántico la reconoce. Limitación restante: miden cercanía con el contexto, no consistencia lógica.

Diagnóstico grupal

- ◆ **KMeans** sobre el perfil por área (PCA a 2D).
- ◆ Agrupa integrantes por fortalezas afines.
- ◆ El generador [reparte roles](#) de un proyecto según eso.



Clustering de perfiles académicos (KMeans, PCA).

— CONCLUSIONES

Qué demostramos

- ◆ Construimos un **pipeline RAG completo**, no una caja negra.
- ◆ El sistema **genera** artefactos con tono, no responde preguntas.
- ◆ La demo con/sin RAG hace **medible** el valor del dato privado.
- ◆ Pipeline de DS completo: EDA, visualización, clustering, evaluación.

Gracias. ¿Preguntas?